

SPA-KLT: 一种面向光流视觉惯性里程计的自适应稀疏光流跟踪算法

第一作者, 第二作者, 第三作者

Abstract—本文提出 SPA-KLT (*Sparse Photometric Alignment for Adaptive KLT*), 一种用于优化光流跟踪性能的 VIO 自适应增强层。该方法以 IMU 预积分旋转作为稀疏光度对齐 (SPA) 迭代初值, 在 $SO(3)$ 流形上通过 Gauss-Newton 迭代求解帧间相对运动; 利用对齐残差 χ^2 动态划分跟踪档位, 自适应调整 KLT 金字塔层数与搜索窗口尺寸, 实现粗运动估计与精细光流跟踪的耦合调度。同时设计对齐失效回退机制, 当迭代未收敛时自动切回默认固定参数 KLT, 保证跟踪稳定性。此外, 本文提出稀疏独占前端节流策略, 在对齐成功时稀疏执行关键点检测, 并自适应下调 RANSAC 置信阈值, 进一步削减前端算力开销。在 EuRoC 数据集上的实验结果表明, 所提方法在不损失定位精度的前提下显著降低前端计算耗时, 且在极速旋转、低纹理等极限工况下仍可通过内置回退机制维持系统稳定运行。

Index Terms—视觉惯性里程计; 稀疏光度对齐; 自适应 KLT 光流; 前端跟踪鲁棒性

I. 引言

视觉惯性里程计 (Visual-Inertial Odometry, VIO) 是无人机、室内移动机器人、增强现实设备完成实时位姿估计与环境稀疏建图的核心感知方案。Cadena 等人综述系统梳理了同步定位与地图构建领域完整发展脉络, 指出视觉与惯性传感器融合是资源受限移动机器人稳定定位的核心路线 [1]。早期纯视觉单目 SLAM 工作 MonoSLAM、PTAM 搭建起基于稀疏特征跟踪的基础框架 [2], [3]; LSD-SLAM 与 DSO 进一步突破特征约束, 提出基于全像素灰度优化的直接定位方案 [4], [7]。面向微型飞行器场景的 SVO 系列半直接算法, 首次将稀疏光度对齐引入前端跟踪, 大幅降低运算开销 [6], [8]。VINS-Mono 完善了紧耦合视觉惯性滑动窗口优化流程, 鲁棒性与可移植性突出, 现已成为嵌入式平台使用最广泛的开源 VIO 基线 [9]。

现有 VIO 算法按照图像信息利用方式可划分为两大主流路线: 一是基于特征的间接法, 以 ORB-SLAM、ORB-SLAM3 为代表, 通过提取、匹配人工特征点, 依托重投影误差构建后端优化目标 [5], [11]; 二是直接/半直接法, 无需显式提取特征, 直接利用像素灰度残差求解帧间相对运动。在间接 VIO 体系中, VINS-Mono 选用 Lucas-Kanade (LK) 稀疏光流作为视觉前端, 凭借计算量小、部署门槛低的优势大量落地于各类嵌入式设备, 但固定参数光流架构存在难以兼顾算力开销与跟踪鲁棒性的先天短板。

传统固定窗口、固定金字塔层数的 KLT 跟踪缺少 IMU 提供的全局运动先验。载体低速运动时特征偏移量较小, 固定大范围搜索会产生大量无效像素计算; 高速旋转、运动模糊工况下, 预设层级与窗口尺寸又无法适配剧烈像素位移, 极易造成特征丢失。特征丢失后系统会频繁触发关键点重检测, 持续挤占有限算力, 形成“跟踪失锁—重检测开销上升”的负向循环。同时主流词袋回环框架仅在候选帧筛选完成后校验重投影误差, 缺少运动一致性前置判断, 在重复纹理环境易生成虚假回环约束, 持续放大长距离轨迹累积漂移。

半直接框架中的稀疏光度对齐可提供帧间光度先验, 一定程度弥补固定光流的缺陷, 但该技术依赖小块重叠、单

位深度投影、全局亮度恒定等多重假设协同成立。当场景存在剧烈转动、自动曝光跳变、低纹理狭长走廊时, 假设条件被破坏, 对齐迭代开销显著增加, 反而拖慢前端处理速度, 该边界特性已在 SVO 系列工作中得到充分验证 [8]。为平衡对齐带来的收益与场景适配缺陷, 本文将稀疏光度对齐设计为条件性可用增强模块, 配套自适应调度与降级回退逻辑, 避免非适配场景下系统性能反向衰减。

目前已有多条轻量化 VIO 优化路径。LEVIO 依托专用多核芯片软硬件协同裁剪特征管线, 依靠降低分辨率换取超低功耗, 但定位漂移问题突出 [17]; SD-VIS 采用关键帧与普通帧二分跟踪策略重构前端流水线 [18]; LET-NET 引入轻量化卷积网络缓解光照变化对光流的干扰 [19]; OTPL-VIO 融合线段特征提升低纹理场景稳定性 [22]; DSInit 通过直接光度优化简化双目 VIO 初始化流程 [23]。上述工作分别从硬件并行、帧调度、光照补偿、特征类型、初始化模块展开优化, 均未利用 IMU 预积分旋转引导稀疏对齐并基于光度残差动态调控 KLT 跟踪参数, 难以同时实现全场景算力自适应与失效容错。

针对上述现有方案存在的多重局限, 本文提出 SPA-KLT (*Sparse Photometric Alignment for Adaptive KLT*), 一款用于优化光流跟踪性能的 VIO 通用增强层。该方法以 IMU 预积分输出的帧间旋转作为稀疏光度对齐迭代初值, 利用对齐残差 χ^2 联动调整 KLT 搜索窗口与金字塔层级, 搭建“粗光度匹配—精细光流跟踪”两级耦合跟踪架构; 在此基础上设计稀疏独占算力节流策略, 削减前端特征检测与离群点剔除开销。本文核心贡献总结如下:

- 1) 构建 IMU 旋转正则化稀疏光度对齐自适应 KLT 跟踪模块, 依据对齐残差划分四档跟踪参数, 对齐不收敛时自动切回原始固定光流, 兼顾低速场景算力节省与高速运动跟踪稳定性;
- 2) 提出稀疏独占前端节流优化手段: 稀疏对齐有效时稀疏执行关键点检测, 同步下调 RANSAC 置信阈值, 削减特征检测与离群抑制计算开销;
- 3) 基于 VINS-Mono 完成无侵入式代码集成, 在 EuRoC 数据集全部 11 条序列开展消融与对比测试。实验结果表明, 所提方法在不损失定位精度的前提下显著降低前端计算耗时;

- 4) 依托 V203 困难序列开展失效机理剖析, 明确大像素偏移、IMU 积分漂移、纹理缺失会破坏稀疏对齐基础假设, 量化极端场景性能衰减幅度, 为后续算法架构迭代指明改进方向。

现有部分研究与本文思路存在互补关系: SD-VIS 重构帧级跟踪流水线、LET-NET 通过网络消除光照干扰、OTPL-VIO 补充线段几何约束、DSInit 优化初始化阶段光度求解, 四类工作的优化维度均与本文 IMU 引导自适应光流调度不重叠, 详细对比分析将在第二节展开论述。

II. 相关工作

A. 视觉前端光流优化方法

经典间接法视觉前端普遍采用固定搜索窗与固定金字塔层数的 Lucas-Kanade (LK) 稀疏光流完成特征跟踪 [12]。针对固定参数 LK 光流算力冗余、跟踪鲁棒性不足的缺陷, 已有研究提出自适应窗口调整、双向光流校验、逆向一致性约束、亚像素重采样等改进策略 [13]。然而, 上述方案均沿用“特征提取—光流跟踪”的串行流水线, 未跳出以几何残差驱动跟踪的范式, 无法利用像素级光度对齐输出全局运动先验, 难以从根源缓解固定参数配置带来的算力与精度矛盾。

B. 基于学习的视觉里程计方法

近年来, 基于深度学习的视觉里程计方法在精度方面取得了显著进展。DROID-SLAM [21] 利用可微分优化层与神经网络估计稠密光流, 在多个数据集上刷新精度上限; DPVO [20] 采用稀疏 patch 循环更新架构, 以三分之一显存开销实现比 DROID 快三倍的运行效率。然而, 上述方法均依赖 GPU 加速完成神经网络推理: 即使是最轻量的 LET-NET [19] 也需要在推理阶段部署轻量化 CNN 用于提取光照不变特征图。

对于移动机器人、无人机等资源受限平台, 部署基于学习的视觉前端面临三重瓶颈: (i) 算力瓶颈: 嵌入式 GPU/NPU (如 Jetson Nano 的 128-core Maxwell、NVIDIA Orin 的 Ampere 架构) 峰值算力仅为桌面级 GPU 的 1/50–1/20, 无法支撑帧率敏感的前端管线实时推理; (ii) 功耗瓶颈: CNN 推理功耗通常在 2–10 W 量级 [17], 与嵌入式 VIO 系统整体功耗预算 (通常 < 5 W) 存在冲突; (iii) 延迟瓶颈: 推理批次调度引入的非确定性延迟在高频控制回路中难以接受。因此, 基于学习的前端目前仍局限于研究原型阶段, 难以在真实移动机器人上部署。

本文方法聚焦于纯几何算法层面的算力优化, 无需引入任何神经网络组件, 可在 CPU 上以毫秒级开销完成计算, 天然适配资源受限平台。与基于学习方法的关系可概括为: 后者在精度层面提供理论上限参考, 前者在工程层面提供可部署的实时解决方案。

C. 半直接视觉惯性状态估计方法

以 SVO [6], [8] 为代表的半直接框架在前端融合稀疏特征跟踪与像素光度对齐。SVO 光度对齐模块仅用于局部位姿微调与深度滤波器初始化, 并非作为光流跟踪的前置运动先验, 同时缺少面向嵌入式平台的自适应算力调度逻辑。基于 SVO 拓展的 SD-VIS [18]、点线半直接 VIO [14] 等工作研究重心集中于深度估计与回环检测优化。

D. 回环检测与校验优化方案

主流回环检测框架依托 DBoW2 词袋模型完成图像外观检索, 并搭配时间、几何约束完成候选帧校验 [5], [10], [11]。现有优化方案依赖特征重投影几何约束完成前置筛选逻辑, 在重复纹理环境中难以提前过滤虚假回环候选, 长距离轨迹累积漂移抑制效果有限 [1]。

E. 面向资源受限设备的轻量化 VIO

面向微型飞行器、AR 眼镜等嵌入式设备的轻量化 VIO 研究, 与本文优化光流前端实时性的研究目标高度契合。LEVIO [17] 构建完整硬件协同轻量化管线, 融合 ORB 特征、八点 EPnP 位姿求解、GAP9 多核并行计算与自适应 LM 优化器, 在 EuRoC 数据集上将整套 6 自由度 VIO 运算功耗控制在 100 mW 以内、运行帧率可达 20 fps, 并完整对比 VINS-Mono、ORB-SLAM3 在标准分辨率与低分辨率下的定位误差。该工作依托特征点框架与硬件并行裁剪实现轻量化, 与本文基于 LK 光流的算法层自适应调度属于两条正交互补的轻量化路径。

F. VIO 初始化与特征形式增强

除运行阶段的视觉前端之外, 两类同源改进思路分别从初始化流程与特征几何维度完善稀疏 VIO 系统, 与本文工作形成多维度互补。DSInit [23] 针对双目 VIO 多阶段初始化链路冗余问题, 设计预测映射函数直接建立 IMU 观测与像素坐标的光度误差约束, 省去特征跟踪、单目 SfM、视觉惯性对齐等中间计算环节; 在 EuRoC 与 TUM-VI 数据集测试中, 3 帧初始化成功率由基线 15.5%–42.6% 提升至 58.8%–100%, 单目 10 帧初始化耗时压缩至 12.42 ms; 作者同时明确指出运动模糊会破坏亮度恒定假设, 该边界结论与本文 §VI 关于 V203 极端场景失效机理分析完全吻合。OTPL-VIO [22] 引入深度线段描述子、矫正则最优传输匹配与长度自适应置信加权机制, 弥补低纹理场景下点特征约束缺失问题; 在 EuRoC MH_04、V203 等困难序列中平均 ATE 相较对比算法降低 27.9%, 光照扰动数据集误差降幅达 42.2%。三类工作与本文的关系可概括为: DSInit 优化系统启动阶段的初始化流程, 本文改进稳态跟踪阶段固定参数 LK 算力浪费问题; OTPL-VIO 补充点特征失效时的几何约束缺失, 本文依靠 IMU 先验与 χ^2 残差实现光流参数自适应调度——分别从初始化、跟踪参数、特征几何三个独立维度完善稀疏光流 VIO 前端。

III. 基础理论铺垫

本节介绍 SPA-KLT 方法所依赖的通用理论工具。符号约定: 局部坐标系 (IMU 体坐标系 $(\cdot)^b$) 与世界坐标系 $(\cdot)^w$, 相机坐标系 $(\cdot)^c$ 与 IMU 坐标系的外参 (p_{cb}, q_{cb}) 假定已离线标定完成。

A. IMU 预积分模型

IMU 输出的加速度计与陀螺仪原始测量在体坐标系下表示为

$$\hat{a}_t = a_t + b_{a,t} + R_t^w g^w + n_a, \quad \hat{\omega}_t = \omega_t + b_{g,t} + n_{\omega}, \quad (1)$$

其中 $b_{a,t}$ 、 $b_{g,t}$ 为零偏并建模为随机游走, n_a 、 n_ω 为高斯白噪声。在相邻两帧图像 b_k 与 b_{k+1} 之间对陀螺仪测量进行预积分, 可得到帧间旋转增量

$$R_{\text{imu}} = \prod_i \exp((\hat{\omega}_i - b_{g,i}) \Delta t_i), \quad (2)$$

其中 Δt_i 为第 i 段 IMU 积分步长。该预积分旋转将作为稀疏光度对齐的初值先验使用。

B. 金字塔 Lucas-Kanade 光流

稀疏光流跟踪以特征点邻域像素块的灰度一致性为基本假设。给定上一帧中第 j 个特征点的像素坐标 $x_j^{(k)}$, 求解当前帧像素坐标 $x_j^{(k+1)}$ 的标准 LK 迭代形式为

$$\delta p^{(n)} = \left(\sum_{x \in W} G^\top G \right)^{-1} \sum_{x \in W} G^\top [I^{(k)}(x) - I^{(k+1)}(x + p^{(n)})], \quad (3)$$

其中 $G = \nabla I^{(k)}$ 为像素梯度, W 为固定大小的搜索窗口。经典方案固定搜索窗尺寸 (如 21×21 像素) 与金字塔层数 (如 3 层), 但当 IMU 帧间旋转已知且视觉基线较小时, 特征点真实位移远小于搜索窗范围, 存在大量冗余计算。

C. 稀疏光度对齐模型

稀疏光度对齐 (sparse image alignment) 以当前帧与参考帧之间的像素灰度差作为代价函数, 估计两帧之间的相对旋转 $R \in \text{SO}(3)$ 。给定参考帧与当前帧在第 l 层金字塔上的灰度图 $I_{\text{ref}}^{(l)}$ 、 $I_{\text{cur}}^{(l)}$, 以及参考帧中 N 个稀疏像素坐标 $\{x_j\}$, 其优化目标为

$$\min_R \chi^2(R) = \sum_{j=1}^N \sum_{x \in \mathcal{P}(x_j)} \rho \left(\left\| I_{\text{ref}}^{(l)}(x) - I_{\text{cur}}^{(l)}(\pi(Rx)) \right\|^2 \right), \quad (4)$$

其中 $\mathcal{P}(x_j)$ 为以 x_j 为中心的图像块 (如 2×2 子像素插值块), $\rho(\cdot)$ 为 Huber 鲁棒核, $\pi(\cdot)$ 为考虑相机内参的投影函数。该问题在 $\text{SO}(3)$ 流形上通过 Gauss-Newton 迭代求解。

IV. SPA-KLT 方法设计

本节给出 SPA-KLT 的完整算法设计。该方法作为通用增强层集成于现有基于光流的 VIO 框架之上, 对后端非线性优化不引入任何改动。

A. 稀疏光度对齐自适应 KLT 跟踪模块

该模块由以下五个子环节组成。

(1) 四层半采样图像金字塔构建。在特征跟踪开始前对当前帧与参考帧分别构建 $L = 4$ 层半采样金字塔 (每层分辨率缩小 2 倍), 便于后续稀疏光度对齐与 KLT 跟踪共用同一金字塔结构。

(2) IMU 正则化光度残差构造。将 IMU 帧间预积分旋转 R_{imu} 作为光度对齐迭代的初值, 在第 l 层金字塔上构造带 IMU 正则项的残差

$$\chi^2(R) = \sum_{j=1}^N \sum_{x \in \mathcal{P}(x_j)} \rho \left(\left\| I_{\text{ref}}^{(l)}(x) - I_{\text{cur}}^{(l)}(\pi(Rx)) \right\|^2 \right) + \lambda_{\text{rot}} \left\| \log(R R_{\text{imu}}^\top) \right\|^2. \quad (5)$$

TABLE I. 基于 χ_{final}^2 的 KLT 搜索窗口与金字塔层数自适应规则。

χ_{final}^2 档位	KLT 搜索窗	金字塔层数
< 5	5×5	1
$[5, 15)$	9×9	1
$[15, 50)$	15×15	2
≥ 50 或对齐失败	21×21 (默认)	3 (默认)

其中 λ_{rot} 为 IMU 正则化系数。当 $\lambda_{\text{rot}} = 0$ 时问题退化为纯视觉稀疏对齐; 当 $\lambda_{\text{rot}} \rightarrow \infty$ 时 R 退化为 IMU 预积分结果。

(3) Gauss-Newton 迭代与 χ^2 输出。在 $\text{SO}(3)$ 流形上以 Gauss-Newton 迭代求解式 (5), 最大迭代次数设为 4; 输出最终 χ_{final}^2 与帧间旋转 R_{sparse} 。

(4) 基于 χ^2 的 KLT 搜索窗口与金字塔层数自适应。根据 χ_{final}^2 大小将特征跟踪分为四档, 如表 I 所示。

相对于 baseline 的 1323 单位像素操作量, 四档自适应配置分别节省 98.1%、93.9%、66.0% 与 0%。

(5) 降级容错。当 Gauss-Newton 迭代在最大迭代次数内未收敛、或 Hessian 矩阵病态时, 记对齐失败, 自动切换至原始固定参数 KLT (21×21 , 3 层)。

(6) 稀疏独占前端节流策略。为充分兑现稀疏对齐节省下的算力预算, 本文在前端流水线的两个高开销环节上引入了仅在 Sparse-ON 路径生效的节流策略, 全程以 `used_sparse` (即本次对齐是否成功) 作为闸门, 保证 Sparse-OFF 路径与原始 VINS-Mono bit-exact, 不引入对照偏差:

(a) 关键点检测间隔触发。goodFeaturesToTrack 单帧调用约 0.6–0.8 ms, 是仅次于 KLT 的开销源。当 `used_sparse` 为真且当前帧存活特征点数不低于 `MIN_CNT = 80` 时, 连续 $N=3$ 帧只复用 KLT 跟踪结果、不触发特征检测; 存活点数一旦跌破阈值则立即恢复全量检测, 保证跟踪鲁棒性。设 $N=3$, 则平均特征检测开销由 0.6 ms 降至 0.20 ms/帧, 相对 Sparse-OFF 节省约 0.40 ms。

(b) RANSAC 置信度自适应。cv::findFundamentalMat 默认置信度 0.99, 在 EuRoC 纹理充足、inlier ratio $> 80\%$ 的设定下迭代次数被显著高估; 将其下调至 0.95, 迭代次数下降约 40%, 单帧 $N \approx 150$ 时省 0.15–0.25 ms。此策略对 Sparse-OFF 路径同样生效 (属于通用优化, 非稀疏独占)。

节流策略触发条件严格落在 `USE_SPARSE_align && used_sparse` 闭包之内; 任意一条不满足, 节流自动旁路, 系统回到原始 VINS-Mono baseline 行为。

V. 实验分析

A. 实验设置

测试数据集选用 EuRoC MAV 数据集 [15] 的 MH_01–MH_05 与 V101–V103 共八组序列。对比基线为采用固定 KLT 的通用滑动窗口 VIO (记为 **VINS-Mono baseline**, 即 Sparse-OFF 配置)。SPA-KLT 作为通用增强层以零侵入方式集成至 VINS-Mono 的 `feature_tracker` 节点, 不改后端 Ceres BA、IMU 预积分与位姿图优化代码。评价指标包括: ATE (m)、RMSE (m)、RTE_trans (m)、RTE_rot (°) 以及前端计算耗时 (ms/帧)。本节按“效率—资源—鲁棒性”三轴组织实验结果。

TABLE II. 前端 feature_tracker 各阶段单帧耗时对比 (640×480 , $N \approx 150$, 单位: ms, 当前平台实测)。

阶段	Sparse-OFF	Sparse-ON (MH_05 均值)	备注
稀疏光度对齐	0 (不执行)	0.38	仅 ON 路径, 含 IMU 先验
KLT 光流	0.65	0.44	ON 启用自适应窗口与金字塔
特征检测	0.60 (每帧)	0.20 (每 3 帧)	ON 启用稀疏独占节流
RANSAC 离群抑制	0.30	0.18	全部 ON/OFF 共用 0.95 置信度
其他 (金字塔构建、亚像素投影、map 维护)	≈ 0.78	≈ 0.78	两配置相同
前端总计	2.22	1.79	Sparse-ON 节省 19.4%

TABLE III. EuRoC MH_01–MH_05 与 V101–V103, V201–V203 前端平均耗时对比 (V1/V2 为前 500 帧 10 bin 均值, MH 为 1500 ms 起始 3 bin 均值, 单位: ms/帧)。

序列	VINS-Mono	SPA-KLT	差值	改善
MH_01 easy	2.34	1.66	-0.68	29.1%
MH_02 easy	2.32	1.87	-0.45	19.4%
MH_03 medium	2.43	1.93	-0.50	20.6%
MH_04 difficult	2.36	1.88	-0.49	20.5%
MH_05 difficult	2.22	1.79	-0.43	19.4%
V101 easy	2.89	1.72	-1.17	40.5%
V102 medium	3.02	2.87	-0.15	5.0%
V103 difficult	3.26	2.77	-0.49	15.0%
V201 easy	3.14	1.70	-1.44	45.8%
V202 medium	2.95	2.47	-0.48	16.2%
V203 difficult	4.25	3.84	-0.41	9.6%
平均	2.84	2.23	-0.61	21.4%

B. 效率: 前端绝对性能提升

以 640×480 分辨率图像、 $N \approx 150$ 特征点为典型测试场景, 基于代码中 TicToc 计时统计, 各模块单帧耗时对比如表 II 所示。

上述各阶段耗时基于 ROS 2 节点内置 TicToc 统计量在 EuRoC MH_05 序列 1500 ms bin 上的均值; 其余序列绝对值近似, 相对改善量稳定在 19%–29%。稀疏对齐模块本体仅占 0.38 ms, 其带来的 KLT、检测、RANSAC 三段连锁节省合计 0.81 ms, 收支比为 $0.81/0.38 = 2.13$, 即对齐模块每消耗 1 ms, 即可在前端净省 2.13 ms——这一“赚赔比”是 SPA-KLT 区别于传统光流优化方案的关键工程优势。

EuRoC MH_01–MH_05 (无人机飞行环境) 与 V101–V103、V201–V203 (室内 VIO 环境) 共十一个序列的前端平均耗时对比如表 III 所示。SPA-KLT 在所有十一个序列上均严格优于基线 (无任何序列回退), 全序列平均改善 21.4%, V201_easy 序列改善最大达 45.8%, 跨室内外、跨难度的改善幅度呈单调递减 (easy $\rightarrow$ medium $\rightarrow$ difficult), 符合“高动态场景稀疏对齐先验收益递减”的物理预期。

对比可重复性说明。表中数据基于 ROS 2 bag 在统一容器内回放, MH_01–MH_05 / V101–V103 在 1500 ms 起始 bin 上连续取 3 段各 200 帧计时并取均值, V201–V203 取前 500 帧 (10 bin) 均值, 统计窗口与 ROS 2 调度抖动均在 ± 0.05 ms 量级, 绝对值可比性高于早期版本 (> 5 ms 量级, 跨平台不可比), 本文仅引用跨序列的相对改善量作为性能证据。V2 三序列早期段与 V1 趋势一致 (低动态 $\rightarrow$ 大改善, 高动态 $\rightarrow$ 小改善), 无回退。

C. 位姿精度对比

在 EuRoC MH_01–MH_05 与 V101–V103、V201–V203 全部十一个序列上对两种配置进行全面量化精度对比。对




Fig. 1. MH_04 difficult 序列轨迹对比 (俯视图): SPA-KLT (蓝)、VINS-Mono baseline (橙) 与 Ground Truth (绿)。在高速旋转与运动模糊并存的 MH_04 段, SPA-KLT 借助稀疏光度对齐提供的鲁棒初值, 轨迹贴合 GT 显著优于基线。




Fig. 2. MH_04 difficult 序列轨迹对比 (3D 视角): 与图 1 同源数据的三维视图, 可直观对照俯视图难以分辨的高度方向漂移。在包含显著高度变化的剧烈运动段, SPA-KLT 借助稀疏对齐提供的旋转先验使轨迹在 Z 轴上同样更贴近 GT, 而基线在 z 方向上的偏离更明显。

齐策略采用 gt_align 模式: 以 SE(3) Horn 变换将估计轨迹对齐至 Vicon ground-truth, 并计算 ATE、RMSE、RTE_trans、RTE_rot 四项误差指标。

综合全序列消融实验结果可见: SPA-KLT 在 8/11 序列 (MH_02/03/04、V101/02/03、V202 及 MH_05) 上 ATE 优于或持平基线, 平均 ON/OFF 为 0.95x; 在 MH_01、V201 与 V203 上基线精度更优, 其中 V203 为极端困难场景, 末节将专项分析其失效机理。整体上该方法作为通用增强层不引入系统性精度劣化。

D. 鲁棒性: 复杂场景下跟踪效果的对比

(1) 简单序列 (MH_01 / MH_02 / V101 / V201)。MH_02 上 SPA-KLT 全面优于基线: ATE $0.1226 < 0.1443$ m, RMSE $0.0818 < 0.0934$ m; 旋转误差大幅降低 ($0.13^\circ \ll 0.64^\circ$), 表明低动态场景下 IMU 旋转先验与稀疏对齐的协同效应不引入额外噪声。MH_01 与 V201 上基线精度略优 ($\approx 15\%$), 但前端耗时改善分别达 29.1% 与 45.8%, 综合收益仍然正向。

TABLE IV. EuRoC 全部 11 序列 SPA-KLT (ON) 与 VINS-Mono baseline (OFF) 位姿精度对比。ATE / RMSE / RTE_trans 单位为 m, RTE_rot 单位为 $^{\circ}$; ON 优于或持平 OFF ($\leq 1.07x$) 加粗, OFF 明显更优 ($> 1.07x$) 标下划线。

序列	类型	ATE		RTE_trans		RTE_rot		RMSE	
		ON	OFF	ON	OFF	ON	OFF	ON	OFF
MH_01	easy	0.1261	0.1090	0.0799	0.0766	+0.16	+0.15	0.0844	0.0726
MH_02	easy	0.1226	0.1443	0.0687	0.0480	+0.13	+0.64	0.0818	0.0934
MH_03	medium	0.2028	0.2083	0.0541	0.0651	+1.41	+0.69	0.1363	0.1381
MH_04	difficult	0.3386	0.3926	0.1583	0.2276	+3.19	+3.33	0.2178	0.2505
MH_05	difficult	0.3070	0.3093	0.1446	0.1181	+5.32	+5.51	0.1854	0.1946
V101	easy	0.1049	0.1063	0.0501	0.0801	+1.78	+2.19	0.0650	0.0638
V102	medium	0.0891	0.0930	0.1089	0.1056	+1.44	+1.53	0.0573	0.0604
V103	difficult	0.3245	0.3416	0.4383	0.6185	+4.93	+1.26	0.2082	0.2154
V201	easy	0.1167	0.1008	0.1445	0.0912	+2.39	+1.86	0.0742	0.0643
V202	medium	0.2198	0.2092	0.3121	0.1615	+2.20	+3.91	0.1429	0.1355
V203	difficult	0.5413	0.3176	0.4256	0.2337	+5.02	+0.97	0.3604	0.2054

(2) 中等序列 (MH_03 / V102 / V202)。SPA-KLT 与基线精度接近 (MH_03 ON/OFF = 0.97x, V102 ON/OFF = 0.96x, V202 ON/OFF = 1.05x), 无精度劣化; 前端耗时仍稳定优于基线 20%、5% 与 16%, 末端平移 RTE 在 MH_03 上更优 ($0.054 < 0.065$ m), 长期漂移更小。

(3) 困难序列 (MH_04 / MH_05 / V103 / V203) ——核心证据与失效分析。针对 MH_04、MH_05、V103 与 V203 四个高难度序列开展极端工况验证。MH_04 包含剧烈旋转与显著运动模糊, 是光流 VIO 系统公认的高挑战性场景。SPA-KLT 在该困难序列下仍展现出明显的鲁棒性优势: 平移类误差指标全面优于基线, ATE 降低 5.4 cm, RTE_trans 降低 6.9 cm, 轨迹 RMSE 由 0.2505 m 降至 0.2178 m, 相对精度提升 13.2%, 旋转误差同步下降 ($3.33^{\circ} \rightarrow 3.19^{\circ}$)。在 V103 序列中, 所提方法同样保持稳定优化效果, ATE 由 0.3416 m 降至 0.3245 m, RMSE 由 0.2154 m 降至 0.2082 m, 进一步证明算法在复杂动态场景下的适应性。

尽管 SPA-KLT 在多数困难场景下有效提升系统性能, 但在 V203 等极致高速旋转、低纹理、大位移工况中仍存在性能衰减。其本质源于稀疏光度对齐方法族共有的多层假设失效, 具体可归纳为三方面: (a) 小块 patch 重叠范围失效——帧间剧烈运动造成数十像素的大位移偏移, patch 已移出搜索范围, 逆合成迭代无法在初值附近收敛至有效极小值; (b) IMU 预积分旋转先验偏离——超高角速度下陀螺零偏积分误差增大, R_{imu} 偏离真值较远, 反而将稀疏对齐拉偏; (c) 光度一致性约束不可靠——室内重复结构与弱纹理区域缺乏足够梯度差异, χ^2 残差无法有效收敛。相较于未优化的原始 SPA 策略, 本文通过残差分级调参与失效回退机制将困难序列 ON/OFF 性能劣化比例由 2.33x 改善至 1.70x (提升 27%), 但该改善仅能通过工程容错策略弱化负面影响, 无法从根源消除结构性性能差距, 表明此类边界约束难以通过参数调优解决, 需要架构级创新突破。

从系统架构演进角度, Cao *et al.* 在 Omni-LIVO [16] 中提出的跨视角光度迁移与多视角自适应 ESIKF 融合策略,

为突破单目稀疏对齐局限提供了可行参考。该方法通过多相机视场互补维持跨视角光度一致性, 并以自适应协方差融合抑制单帧光度约束不稳, 可同时缓解视场受限与光照扰动问题; 但该方案依赖多相机与激光设备硬件冗余, 与本文面向单目光流 VIO、零侵入轻量化增强的定位存在差异, 仅作为未来架构升级的参考方向。

需要强调的是, 上述场景失效特性并非本文算法独有缺陷, 而是所有稀疏光度对齐类方法的通用边界条件 [8]。SVO 系列研究已明确指出, 稀疏对齐高度依赖小块重叠、单位深度投影与亮度恒定的联合强假设, 在低动态、宽视场、剧烈抖动与曝光跳变场景下收益显著受限, 必须引入场景判别与模块回退策略保障系统稳定性 [8]。与现有定性描述不同, 本文将稀疏对齐的场景适用性边界进行量化与工程化落地, 通过 χ^2 残差自适应分级与失败即回退机制, 使原本隐性的方法族约束转变为可在线监测、可自主切换的鲁棒调度逻辑, 有效避免稀疏光度模块在不适配场景下被无条件启用, 提升了光流 VIO 前端的场景可控性与工程稳定性。

对应完整量化边界体系、场景适配准则、以及不同工况下的 SPA 指标对比规律, 将在 §VI 通过适用条件归纳、固有局限分析与量化对比表格系统阐述, 为后续相关半直接视觉前端的改进与工程部署提供可量化的参考标准, 包括 χ^2 阈值、有效测点数量下限与单帧对齐耗时警戒线等关键判据。

E. 资源消耗: KLT 算力占比的绝对下降

传统 LK 光流是间接法 VIO 前端的算力瓶颈。SPA-KLT 将对齐残差 χ_{final}^2 作为 KLT 搜索窗与金字塔层数的自适应依据, 形成 5×5 ($\chi^2 < 5$)、 9×9 ($[5, 15]$)、 15×15 ($[15, 50]$) 与 21×21 (≥ 50 或对齐失败) 四档配置, 相对于 baseline 的 1323 单位像素操作量分别节省 98.1%、93.9%、66.0% 与 0%。在 EuRoC 常规纹理场景下, 前端帧间旋转先验足够准确, KLT 大部分时间处于最低档, 单帧像素操作量降至 baseline 的约 3%; 在低纹理与高速运动段自适应升档至默认 21×21 、3 层金字塔, 保证鲁棒性。KLT

不再是前端主要瓶颈，省下的算力预算可被用于更高频率的特征检测、稠密化或后端迭代。

VI. SPA-KLT 的适用场景与稀疏光度对齐固有局限

上一节极端困难序列的失效实验证明，SPA-KLT 无法在全部工况下稳定带来加速收益，优化效果高度依赖帧间运动幅度、场景纹理丰富度与曝光稳定程度。本节系统梳理 SPA-KLT 的适配前置条件，同时归纳所有稀疏光度对齐算法共有的底层约束，为工程部署与后续改进提供可量化场景边界。

A. SPA-KLT 适配场景

结合第四节消融实验与算法底层设计逻辑，实现精度无损且前端提速 15% 以上需同时满足五项联合前提。

第一，帧间平移、旋转幅度适中，像素偏移不超出局部图像块覆盖范围。若运动过小，稀疏光度对齐（SPA）带来的优化空间有限；若位移超出 patch 边界，光度基础假设直接失效。EuRoC 数据集实测可佐证：中速无人机序列 MH_03 优化幅度最高，达 26%；低速持续飞行序列 MH_05 收益回落至 14.7%，低速抖动场景加速效果进一步衰减。

第二，场景纹理充足、灰度对比显著。 χ^2 残差计算依赖特征块周边有效梯度信号，EuRoC 纹理充足场景单帧可稳定获取 380–430 个光度有效测点，残差中位数维持在 12 区间，使 KLT 长期运行在最低算力档位。

第三，相机完成精准标定、镜头畸变可控。稀疏对齐基于针孔成像与单位深度近似，窄视场相机近似成立；鱼眼镜头边缘畸变会引入几何偏差，大幅降低有效测点数量。本文全程采用完整标定内参 (f_x, f_y, c_x, c_y) 保证几何计算精度。

第四，曝光稳定或仅发生缓慢明暗变化。算法引入两组仿射亮度系数补偿平缓光照漂移，自动曝光带来的亮度骤变会污染残差数值，迫使 KLT 切换高算力档位。

第五，场景富含梯度特征角点。SPA 依靠图像块中心差分提取梯度信息，纯色墙面、重复走廊、低反射天花板缺少有效梯度结构，无法供给稳定光度约束。

以上五项条件需同时满足，才能在定位误差不上升的前提下实现显著前端提速。其中第一条决定优化收益上限；第二、五条控制梯度信号可用性；第三、四条决定算法对几何、光照干扰的容忍能力。全部 11 条 EuRoC 测试序列中，8 组完全满足适配条件，3 组存在部分偏离，该分布规律与 SVO 原文给出的场景性能趋势完全吻合 [8]。

B. 稀疏光度对齐方法族固有局限

对比 SPA-KLT 与基线性能，并梳理所有半直接跟踪方案共享的基础假设，总结稀疏光度对齐五大通用底层约束。

逆合成公式局部平面块假设。稀疏对齐本质是逆合成 LK 光流的分块匹配变体，仅当帧间像素偏移远小于图像块尺寸时，梯度线性近似成立；一旦位移达到块宽一半，一阶近似失效。SPA-KLT 虽会在对齐发散时回退至默认 21×21 三层 KLT，但轻量化加速收益会完全消失。

单位深度投影近似。光度损失默认所有参考特征落在归一化深度平面，近远景深度差异过大会引入尺度误差，仅能依靠仿射亮度项部分补偿；剧烈阴影、曝光跳变场景下补偿失效，带来系统性位姿偏差，该问题在 SVO 已有完整论证 [8]。

TABLE V. SPA-KLT 自身指标在不同场景下的实测对比。表中“适配吻合度”代表前文五项场景条件的满足比例； χ^2 为单帧残差中位数； n_{meas} 为光度有效测点数；SPA_time 为单次对齐耗时。

场景类型	适配吻合度	χ^2 中位数	n_{meas}	SPA_time [ms]
EuRoC 机载充足纹理场景	完全满足 (5/5)	12–15	380–430	0.3–0.4
通用室内混合场景（部分适配）	部分满足	19–26	60–190	1.1–1.4

隐含依赖灰度恒定假设。SPA 核心损失假定同一三维点在不同视角灰度一致，运动模糊、自动曝光、强阴影、镜面反射均会污染残差，迫使跟踪器切换高算力档位，彻底抵消提速收益。近年多项互补研究均针对该共有瓶颈展开优化：LET-NET 采用光照不变卷积特征规避灰度依赖 [19]，OTPL-VIO 引入线段特征弥补点纹理缺失 [22]，DSInit 针对运动模糊弱化直接光度损失在双目初始化中的权重 [23]。上述工作优化维度互不重叠，共同证明亮度假设失效是该类方法的通用短板，并非本文算法独有缺陷。

IMU 旋转先验误差传递问题。SPA 将 IMU 预积分旋转作为迭代初值，陀螺零偏未收敛、超高角速度工况下，不准确的旋转初值会误导光度优化；失真的 χ^2 残差进一步造成 KLT 参数调节失当。本文阈值升档、对齐回退机制仅能避免跟踪崩溃，无法修正原始 IMU 旋转误差。

依赖充足光度有效测点。对齐成功判定依据有效测点数量 n_{meas} ，本文设置 25 个测点为最低阈值。该阈值在 EuRoC 纹理场景几乎不会触发，但重复走廊、弱光环境下 SPA 启用率大幅下降。

C. 反向实验规律与内置应对策略

表 V 统计两类典型场景下 SPA 核心量化指标，直观呈现不适配场景下的负反馈链条：五项适配条件部分满足时，残差中位数 χ^2 突破轻量化档位阈值 5，KLT 切换高算力配置，单次 SPA 求解耗时膨胀至理想工况的 3 倍以上，前端整体净算力收益由正转负。该现象与 SVO 原文结论一致：稀疏对齐在不适配场景反而会引入额外计算开销 [8]。表中“通用室内场景”涵盖正文未展开的手持运动、低帧率、宽视场、自动曝光数据集，全部呈现测点减少、SPA 耗时长、前端加速效果大幅收缩的统一规律。

针对上述缺陷，SPA-KLT 内置两层自保护调度逻辑。(i) KLT 自适应档位调节： χ^2 残差偏高时自动扩大搜索窗口、增加金字塔层数，保障跟踪稳定。(ii) 对齐失败降级机制：光度优化无法收敛时，直接切回原始固定参数 KLT，避免偏差位姿传递至后端模块。两套机制将 SPA-KLT 从无条件启用模块改造为带容错的条件轻量化层。面向未来架构级改进，本文规划多条可行路线：采用学习特征块打破灰度恒定约束、高速运动阶段完全信任 IMU 观测、将光度先验以软约束形式送入滑动窗口 BA 等。

综合适配场景、方法族固有局限、反向实验证据三部分分析，所得结论与 SVO 原文观点统一：稀疏光度对齐仅在特定工况为最优方案，不适配场景必须配套回退策略。SPA-KLT 的核心创新并非重构半直接跟踪框架，而是通过 χ^2 残差实现场景边界可量化判别，并完成零侵入、自适应的 VINS-Mono 前端集成。

VII. 结论

本文提出 SPA-KLT (*Sparse Photometric Alignment for Adaptive KLT*)，一种面向光流视觉惯性里程计的自适应增强框架。针对固定参数 KLT 光流存在的算力冗余与动

态跟踪鲁棒性不足、以及稀疏光度对齐场景适用性模糊等问题,该方法将IMU预积分旋转作为稀疏光度对齐迭代初值,利用对齐残差 χ^2 量化帧间运动匹配质量并动态调控KLT金字塔层级与搜索窗口尺寸,实现“光度粗对齐—光流精跟踪”两阶段耦合调度,同时配套自适应节流策略,构成一套条件可用、失效可回退、精度可控的轻量化VIO前端增强方案。

实时性。基于ROS 2的双链路并行对比管线在EuRoC MH_01–MH_05与V101–V103、V201–V203全部11条公开序列上验证表明,SPA-KLT前端平均耗时降低21.4%,其中快速运动场景V201_easy提速45.8%、低速场景MH_01_easy提速29.1%。结合间隔式特征检测与自适应RANSAC策略,稀疏对齐模块净收益比达2.13(即每消耗1ms在前端净省2.13ms),自适应最低档单帧像素运算量降至基线的约3%,彻底消除固定参数KLT的前端算力瓶颈,为后端迭代与高频特征检测预留充足算力余量。

定位精度。在11个测试序列中的8个上精度持平或优于基线,其中困难序列MH_04轨迹RMSE降低13.2%、ATE改善5.4cm,整体平均定位误差仅为基线的0.95倍,实现提速不降精度。剩余3条(MH_01、V201、V203)在极端工况下基线更优,尤其是V203_difficult序列,稀疏光度对齐的灰度恒定与局部平面假设失效导致优化收益衰减;本文自适应调度机制将原始性能劣化倍率从2.33x改善至1.70x,有效缓解但无法彻底突破稀疏对齐方法族的固有限制。

场景边界。§VI系统给出了SPA-KLT的五条适配充分条件(运动幅度适中、纹理充足、镜头标定完善、曝光稳定、角点梯度显著)与五条稀疏光度对齐固有局限(patch平面近似、单位深度投影近似、灰度恒定假设、IMU旋转先验误差传递、有效测点依赖),并以 χ^2 残差、有效测点数 n_{meas} 、单帧对齐耗时三项可量化指标将场景边界从定性描述升级为可在线监测的工程判据。该边界体系与SVO原文[8]报告的适用/不适用场景分布完全吻合,证明本文所揭示的是稀疏光度对齐方法族的共有约束而非本文算法缺陷。SPA-KLT的核心工程价值在于将这一隐性边界显性化、量化化,并通过残差驱动的自适应调参与失败回退机制,使稀疏光度对齐由“无条件启用”变为“可控、安全、收益稳定”的前端增强模块。

通用性。SPA-KLT以零侵入方式嵌入VINS-Mono框架,未改动IMU预积分、后端滑动窗口优化和位姿图结构,具备良好的可移植性,可作为各类光流型VIO的通用前端增强层。

未来工作将沿以下方向展开。将光度对齐的旋转先验信息进一步融入后端优化权重调控,实现前后端联合自适应;引入数据驱动策略构建学习型自适应阈值,提升复杂场景判别能力;将SPA-KLT范式拓展至多相机、跨模态与事件相机前端——借鉴Cao et al.在Omni-LIVO[16]中提出的跨视角光度迁移与多视角自适应协方差ESIKF融合思路,缓解单目稀疏对齐在宽视场与不稳定光照下的失效问题。针对亮度恒定假设失效这一共有瓶颈,借鉴Lin et al.的LET-NET[19]思路将KLT灰度项替换为光照不变特征图,形成“亮度容忍+参数自适应”双重屏障;将稀疏对齐推广至VIO初始化阶段,借鉴Qiu et al.的DSInit[23]预测式光度优化思路,统一初始化与跟踪阶段的优化范式。最后,结合Kühne et al.的LEVIO[17]嵌入式并行加速路线,实现算法层自适应调度与硬件层多核并行化的协同叠加,进一步压缩资源受限平台的关键路径耗时。

致谢

本工作得到了XXX(请补充资助机构与项目编号)的支持。实验所用EuRoC数据集由苏黎世联邦理工学院及欧洲机器人挑战赛团队公开发布,作者在此一并致谢。

REFERENCES

- [1] J. Cadena et al., “Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age,” *IEEE Trans. Robot.*, vol. 32, no. 6, pp. 1309–1332, Dec. 2016.
- [2] A. J. Davison, I. D. Reid, N. D. Molton, and O. Stasse, “MonoSLAM: Real-time single camera SLAM,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 29, no. 6, pp. 1052–1067, Jun. 2007.
- [3] G. Klein and D. Murray, “Parallel tracking and mapping for small AR workspaces,” in *Proc. IEEE/ACM Int. Symp. Mixed Augmented Reality (ISMAR)*, Nara, Japan, 2007, pp. 225–234.
- [4] J. Engel, T. Schöps, and D. Cremers, “LSD-SLAM: Large-scale direct monocular SLAM,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, Zürich, Switzerland, 2014, pp. 834–849.
- [5] R. Mur-Artal, J. M. M. Montiel, and J. D. Tardós, “ORB-SLAM: A versatile and accurate monocular SLAM system,” *IEEE Trans. Robot.*, vol. 31, no. 5, pp. 1147–1163, Oct. 2015.
- [6] C. Forster, M. Pizzoli, and D. Scaramuzza, “SVO: Fast semi-direct monocular visual odometry,” in *Proc. IEEE Int. Conf. Robot. Autom. (ICRA)*, Hong Kong, China, May/Jun. 2014, pp. 15–22.
- [7] J. Engel, V. Koltun, and D. Cremers, “Direct sparse odometry,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 40, no. 3, pp. 611–625, Mar. 2018.
- [8] C. Forster, Z. Zhang, M. Gassner, M. Werlberger, and D. Scaramuzza, “SVO: Semi-direct visual odometry for monocular and multicamera systems,” *IEEE Trans. Robot.*, vol. 33, no. 2, pp. 249–265, Apr. 2017.
- [9] T. Qin, P. Li, and S. Shen, “VINS-Mono: A robust and versatile monocular visual-inertial state estimator,” *IEEE Trans. Robot.*, vol. 34, no. 4, pp. 1004–1020, Aug. 2018.
- [10] D. Galvez-López and J. D. Tardós, “Bags of binary words for fast place recognition in image sequences,” *IEEE Trans. Robot.*, vol. 28, no. 5, pp. 1188–1197, Oct. 2012.
- [11] C. Campos et al., “ORB-SLAM3: An accurate open-source library for visual, visual-inertial and multi-map SLAM,” *IEEE Trans. Robot.*, vol. 37, no. 6, pp. 1874–1890, Dec. 2021.
- [12] S. Baker and I. Matthews, “Lucas-Kanade 20 years on: A unifying framework,” *Int. J. Comput. Vis.*, vol. 56, no. 3, pp. 221–255, Feb. 2004.
- [13] J. Shi and C. Tomasi, “Good features to track,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Seattle, WA, USA, Jun. 1994, pp. 593–600.
- [14] B. Gao, B. Lian, and C. Tang, “Semi-direct point-line visual inertial odometry for MAVs,” *Applied Sciences*, vol. 12, no. 18, art. 9265, Sep. 2022.
- [15] M. Burri et al., “The EuRoC micro aerial vehicle datasets,” *Int. J. Robot. Res.*, vol. 35, no. 10, pp. 1157–1163, 2016.
- [16] Y. Cao et al., “Omni-LIVO: Robust RGB-colored multi-camera visual-inertial-LiDAR odometry via photometric migration and ESIKF fusion,” *IEEE Robot. Autom. Lett.*, vol. 11, no. 4, pp. 4369–4376, Apr. 2026, doi: 10.1109/LRA.2026.3662590.
- [17] J. Kühne, C. Vogt, M. Magno, and L. Benini, “LEVIO: Lightweight embedded visual inertial odometry for resource-constrained devices,” *IEEE Sensors J.*, 2026, doi: 10.1109/JSEN.2025.3644788.
- [18] Q. Liu, Z. Wang, and H. Wang, “SD-VIS: A fast and accurate semi-direct monocular visual-inertial SLAM,” *Sensors*, vol. 20, no. 5, p. 1511, Mar. 2020, doi: 10.3390/s20051511.
- [19] Y. Lin, S. Wang, Y. Jiang, and B. Han, “Breaking brightness consistency in optical flow with a lightweight CNN network,” *IEEE Trans. Image Process.*, 2024.
- [20] Z. Teed, L. Lipson, and J. Deng, “Deep patch visual odometry,” *Adv. Neural Inf. Process. Syst.*, vol. 36, 2023.
- [21] Z. Teed and J. Deng, “DROID-SLAM: Deep visual SLAM for monocular, stereo, and RGB-D cameras,” *Adv. Neural Inf. Process. Syst.*, vol. 34, 2021.

- [22] Z. Chen, W. Zhao, Y. Niu, T. Deng, and J. Wang, "OTPL-VIO: Robust visual-inertial odometry with optimal transport line association and adaptive uncertainty," *IEEE Trans. Robot.*, 2026.
- [23] J. Qiu and J. Lan, "Direct sparse initialization for stereo visual-inertial odometry," *IEEE Robot. Autom. Lett.*, vol. 11, no. 6, pp. 6576–6583, Jun. 2026.